DL

DEEP LEARNING

PROYECTO FINAL

New Technology School

Tokio.

ESCENARIO

Para el desarrollo del proyecto final del curso, deberemos construir un **modelo de razonamiento basado en Deep Learning** cuyo proceso de predicción sea accesible a través de una API.

Para ello tendremos que buscar un conjunto de datos (*Dataset*) de tamaño considerable y construir una red de neuronas que genere un modelo sobre el *DataSet*. Una vez construido el modelo deberá ser productivizado mediante una API de tipo REST.

Para la selección del conjunto de datos se recomiendo utilizar algunos de los enlaces que se incluyen a continuación donde se encuentran diferentes *dataset* que pueden ser de interés y un punto de partida excelente:

- Listado de conjunto de datos de CMU: link
- Buscador de conjunto de datos de Google: link
- Listado de conjuntos de datos relacionados con el Procesamiento del Lenguaje Natural: link
- Listado de conjuntos de datos recogidos por la ESA: link
- Listado de conjuntos de datos en Kaggle: link

De entre tantos, **¿qué dataset debemos escoger?**

Queremos dejar la elección del *dataset* abierta para que escojas el que prefieras, aquel relacionado con una aplicación que te interese o que se pueda emplear en un proyecto de mayor o menor dificultad.

Algunos consejos a la hora de escoger un *dataset*:

- Comprobamos el tamaño del mismo. ¿Tiene un nº de ejemplos suficiente? ¿Qué ratio de características a ejemplos tiene? ¿Qué tamaño de *dataset* viene cabiendo en la memoria de nuestro entorno de trabajo?...
- Sin embargo, siempre recordaremos que no tenemos por qué usar todos los ejemplos para entrenar nuestro modelo, también podemos escoger un *subset* de datos aleatorios.

Del mismo modo, lo que es más importante aún, debemos recordar que **no hay por qué usar todas las características disponibles en el dataset**. ¿Cuáles son las más importantes? ¿Son todas

relevantes? ¿Cuánta complejidad, requisitos de memoria y tiempo de entrenamiento añade cada nueva característica, para ganar cuánta precisión finalmente?

DESARROLLO

Una vez seleccionado el correspondiente Dataset, construiremos un modelo y lo productivizaremos siguiendo los siguientes pasos:

1. Definición del problema, de los objetivos y de las hipótesis iniciales.
2. Desarrollo del proceso de carga de los datos.
3. Desarrollo de los procesos de limpieza y preparación de los datos.
4. Análisis de los datos e identificación del tipo de red de neuronas a utilizar.
5. Construcción del modelo de razonamiento.
6. Construcción del sistema de predicción mediante una API de tipo REST.
7. Desarrollo de la documentación.

Se deberá justificar el tipo de red de neuronas utilizada, presentar los resultados y las conclusiones que permitan refutar alguna de las hipótesis iniciales.

Este proyecto es una oportunidad para utilizar nuevas librerías, herramientas o técnicas sobre las cuales no hemos podido profundizar durante el desarrollo del curso que se encuentran relacionados con la construcción de modelos basados en Deep Learning.

ENTREGA

Para la evaluación del proyecto**, será necesaria la entrega de un documento en formato PDF**, donde se deberá incluir toda la información referente al proceso de desarrollo del proyecto, así como diferentes capturas de las actividades realizadas. Es necesario recordar que el objetivo del proyecto, y del trabajo del científico de datos, no es presentar el proceso final, sino intentar documentar todo el proceso seguido.

Un "cuaderno del científico" siempre tiene apuntadas todas las observaciones, hipótesis, experimentos y sus resultados, lo cual le permite al científico, de datos en este caso, recordar en todo momento qué experimentos había realizado, qué resultado habían tenido y por tanto por qué había continuado o no por ese camino.

Por ese motivo se propone plantear, antes de comenzar, 3-4 hipótesis de tipos de modelos.

Al principio puede ser un poco engorroso el andar tomando nota de los resultados y los pasos que vamos dando, pero según evolucione el entrenamiento de nuestro modelo, agradeceremos el haber ido documentando el proceso para dar menos pasos atrás.

Como sucede en el mundo del desarrollo de software, siempre se recomienda documentar el código, no sólo para poder trabajar junto a otros, sino también para nosotros mismos, cuando volvamos a retomar un proyecto un tiempo después y hayamos olvidado qué hicimos y por qué.

Se deberán entregar todos los ficheros ejecutables, conjuntos de datos, datasets, enlaces o cualquier recurso adicional necesario para la ejecución del proyecto. Todo ello, tanto los ficheros como el pdf se deberán entregar en un fichero comprimido que cumpla el siguiente formato de nombrado:

proyecto_dl_nombre_apellido1_apellido2.zip

Para ayudar a la realización de la documentación a entregar, se facilita una plantilla. No es obligatorio utilizarla, pero se recomienda su utilización.

Los plazos de corrección serán de entre 7 y 15 días desde la fecha de entrega.

Junto con el feedback y la nota, el profesor formulará tres preguntas sobre el proyecto, las cuales serán respondidas en un video y esto se considerará la defensa del proyecto.

Esta defensa tendrá una longitud aproximada de 10 minutos y el plazo de corrección será de 7 días desde la fecha de entrega.